

Otimização Conjunta de Vazão e Energia em Redes LoRaWAN Multi-Gateway: Uma Abordagem Baseada em Otimização Multi-Objetivo

Ivan Neves, Caio Cardoso, Fabricio Barros, Jasmine Araujo
Universidade Federal do Pará
Belém, Pa, Brasil

Maio 2025

Resumo

A otimização em redes LPWANs , considera desafios em termos de dinamicidade, eficiência energética e confiabilidade. Para isso, foram avaliadas técnicas baseadas em algoritmos evolutivos, destacando-se os Algoritmos Genéticos (AG), o Flower Pollination Algorithm (FPA) e também o métodos clássicos como o solver CVX do Matlab. Os resultados indicam que os GA, mesmo não disponibilizando maior vazão que o CVX, proporcionam maior eficiência energética na maioria das configurações de dispositivos e atribuições de pesos, prolongando a autonomia dos dispositivos, enquanto o FPA, embora ligeiramente inferior nesses aspectos, apresenta menor tempo de execução, mostrando-se mais adequado para aplicações que exigem menor tempo de resposta. Assim, evidencia-se um trade-off entre durabilidade e agilidade, permitindo selecionar a técnica mais apropriada conforme o perfil da aplicação.

Palavras Chaves— LoRaWAN, Planejamento de Redes, IoT, Metaheurísticas, Redes de Sensores.

1 Introdução

O rápido avanço e expansão da Internet das Coisas (IoT) resulta em um crescimento exponencial dos dados gerados e consumo de energia. Tal avanço e expansão representam novos desafios para abordagens centralizadas e convencionais baseadas em eficiência energética e taxa de entrega de pacotes em redes que necessitam transmitir em longas distâncias. As redes Low Power Wide Area Network (LPWANs) foram criadas para suprir esses desafios já que viabiliza cenários de grande escala, permitindo comunicações eficientes entre dispositivos heterogêneos. Um exemplo desse tipo de rede é o LoRaWAN que traz modelos de sistemas com maiores eficiências de acordo com [Loubany et al., 2020], demonstrado na figura 1, que ilustra a topologia em estrela do LoRaWAN: nós finais comunicam-se com gateways, que encaminham dados ao servidor de rede. Essa arquitetura centralizada reduz complexidade nos dispositivos, favorece longo alcance em bandas não licenciadas e baixo consumo.

Em Agricultura 4.0, a combinação de sensoriamento em grande escala, telemetria e atuação distribuída exige conectividade de longo alcance com baixo consumo, interoperabilidade e custos reduzidos; nessas condições, arquiteturas LPWAN como LoRaWAN viabilizam monitoramento contínuo e tomada de decisão baseada em dados [Javaid et al., 2022]. Estudos comparativos reforçam os compromissos entre alcance, taxa de dados, robustez e energia, posicionando o LoRaWAN como alternativa de amplo alcance e baixo consumo com topologia simples e boa escalabilidade [Mekki et al., 2019].

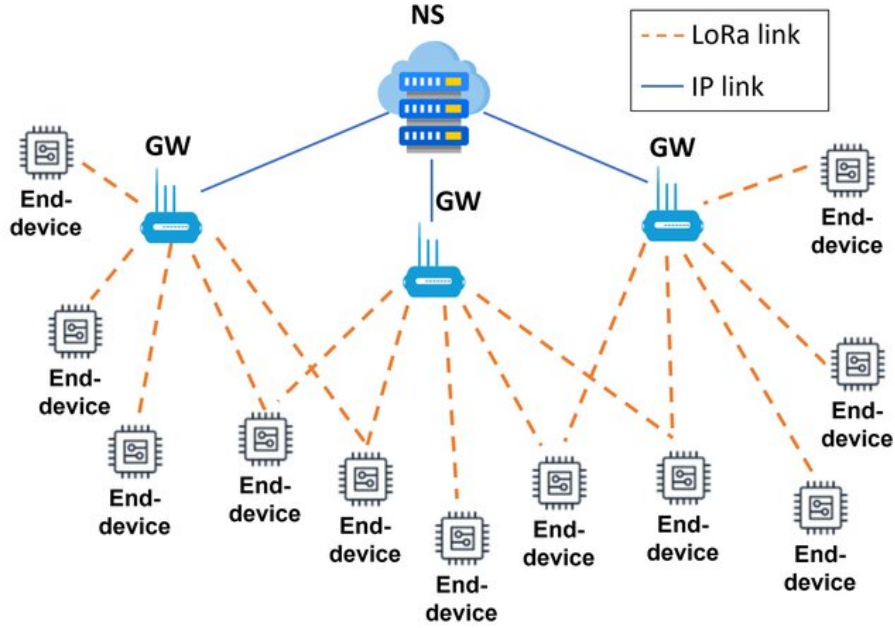


Figura 1: Topologia em estrela do LoRaWAN: nós finais (end devices) → gateways → servidor de rede.

Entretanto, o aumento do número de dispositivos para cobrir áreas amplas traz desafios de consumo energético e degradação do enlace, sobretudo por colisões de pacotes decorrente da configuração inadequada do fator de espalhamento (SF), largura de banda (BW), code rate (CR) e potência de transmissão. Abordagens de ajuste dinâmico de parâmetros e formulações de otimização multiobjetivo apresentam bons resultados em ambientes controlados, porém a complexidade e os tempos de convergência ainda limitam a aplicação prática em cenários dinâmicos com restrições de energia e processamento com mostrados nos trabalhos de [Zheng et al., 2024, Jiang et al., 2022]. Nesse contexto, justifica-se o desenvolvimento de métodos leves e reativos para seleção em tempo real desses parâmetros baseados em heurísticas e metaheurísticas de baixa complexidade que equilibrem qualidade de solução, tempo de convergência e consumo de recursos, preservando escalabilidade e robustez da rede. Assim, o objetivo deste trabalho é propor e avaliar ambientes que agregam modelos de sistemas em conjunto com métodos de otimização para configuração de parâmetros de enlace em redes LoRaWAN, capaz de maximizar a eficiência energética e operar sob restrições diversas.

2 Motivações e Trabalhos Relacionados

A otimização conjunta de vazão e consumo de energia em redes LoRaWAN demonstra que a distribuição inteligente de parâmetros de transmissão, aumenta a eficiência sem comprometer a confiabilidade. O trabalho feito em [Loubany et al., 2023] mostra que seleção ótima de proporções de dispositivos para cada SF, feito pelo solver CVX, supera a eficiência energética do algoritmo Adaptive Data Rate (ADR) e algoritmos de última geração nos cenários investigados.

O artigo [Abdelhedi et al., 2025] apresenta a LoRaWAN como destaque entre as LPWANs para IoT por combinar longo alcance, baixo consumo e bom custo-benefício, e relata uma avaliação experimental do impacto do SF, BW e CR no desempenho da comunicação, além de medir a comunicação ponta a ponta ao integrar LoRaWAN com Message Queuing Telemetry Transport (MQTT). Os resultados evidenciam trade-offs entre SF, BW e CR, mostrando que configurações adequadas melhoram a rede conforme os requisitos da aplicação e que, em ambiente interno, a LoRaWAN oferece comunicação confiável.

Destaca-se a investigação do recurso de retransmissão no LoRaWAN, proposto como solução para ampliar o alcance e a cobertura em cenários de IoT agrícola e monitoramento remoto. O trabalho em [Maurya et al., 2024], entretanto, que essa funcionalidade traz um forte trade-off energético, a sobrecarga de sincronização entre nó final e relé pode elevar o consumo em mais de 100% para transmissões em SF7 e quase 950% em SF12, tornando a solução custosa em termos de autonomia de bateria. Os resultados sugerem que os ganhos de cobertura e a possibilidade de operar com fatores de espalhamento mais baixos podem, em certos cenários, reduzir o tempo de transmissão e compensar parte desse consumo extra, aumentando a vida útil da bateria em até 75%. Contudo, sem benefício real de cobertura, o uso do

relé pode reduzir drasticamente a autonomia, chegando a quedas de cerca de 90%. Assim, o LoRaWAN Relay deve ser considerado apenas quando a cobertura adicional é crítica e o custo energético pode ser administrado. Isso evidencia que melhorias de cobertura e confiabilidade em LoRaWAN exigem um equilíbrio delicado entre eficiência energética e desempenho da rede.

A agricultura inteligente exige interconectar muitos nós em áreas extensas; LoRaWAN resolve o alcance com baixo consumo, mas a energia limitada dos dispositivos segue crítica. O [Sahu and Tripathi, 2024], propõe um algoritmo genético para otimizar WSNs agrícolas e LoRaWAN, incluindo posicionamento de gateways e nós, e ajustes de parâmetros (p.ex., ADR), visando maior eficiência energética e confiabilidade. Em simulação, o AG melhorou simultaneamente FITNESS(EC) (energia) e FITNESS(REL) (confiabilidade) ao longo das gerações, alcançando boa cobertura com custo computacional considerado viável para larga escala. Entretanto, à limitações como dependência de ambiente simulado e potencial custo do AG em redes muito grandes.

Em [Neves et al., 2024], comparam-se métodos clássicos e metaheurísticas para controlar o fator de espalhamento (SF) em redes densas, maximizando a vazão para diferentes quantidades de nós. O procedimento determina quantos dispositivos devem adotar cada SF e, em seguida, ordena os nós por relação sinal-ruído de forma decrescente para atribuir os SFs proporcionalmente ao valor ótimo encontrado, de forma sequencial. O solver CVX entrega vazões ligeiramente superiores, sobretudo acima de 1100 nós, enquanto a metaheurística FPA é cerca de $5\times$ mais rápida, tornando-se adequada quando o tempo de execução é crítico. Há, portanto, um trade-off claro entre desempenho e custo computacional.

Em posicionamento ótimo de nós, metaheurísticas também têm sido empregadas com bons resultados. Em [Al-zamili and Al-Zubaidi, 2024], PSO e AG são aplicados ao arranjo de nós em WSNs de IoT para eliminar lacunas de cobertura e melhorar conectividade: partindo de posições aleatórias e do cálculo de link margin, ambos otimizadores ajustam as coordenadas maximizando a área coberta em um cenário controlado (10 nós, área de 10×10 m, raio de transmissão de 2 m). Os dois métodos convergem e reduzem os “buracos” de cobertura; o PSO alcança fitness ligeiramente superior (1.01684 vs. 1.02351 do GA). A configuração experimental inclui AG com população 20 por 100 gerações e PSO com enxame 40 por 100 iterações (inércia 0,8). As principais limitações residem na função-objetivo simplificada (cobertura binária por distância), sem modelagem de energia, interferência, taxa de dados ou perdas reais de canal. Conclui-se que PSO e AG são viáveis para o planejamento de cobertura; contudo, a generalização requer estudos com métricas energéticas e cenários mais realistas e em maior escala.

Para nós móveis em cenários agrícolas, [Wang et al., 2024] introduz um ADR reativo que substitui a janela fixa do ADR padrão por decisões por pacote baseadas em SNR, RSSI, desvio de frequência, velocidade e distância ao gateway, ajustando dinamicamente a janela M, a margem de sinal (margin margindb) e a combinação [SF,BW] (125/250/500 kHz) com controle de potência. Em simulação e em campo, a abordagem supera o ADR padrão e o Blind ADR, elevando a DER (+18% em simulação; +11% em campo), reduzindo o tempo no ar (50%), colisões e consumo energético (45–59%) e convergindo mais rápido; ao explorar 18 combinações [SF,BW], também mitiga a “categorização” de nós em redes densas. As limitações incluem maior frequência de ajustes em alta mobilidade e a observância de restrições regulatórias para larguras de banda ampliadas.

3 Contribuições

Neste artigo, propomos duas metaheurísticas, adaptadas, em duas etapas para melhorar, a escalabilidade e a confiabilidade de redes LoRaWAN com múltiplos gateways. Primeiro, formulamos um problema de otimização baseado em multiobjetivo que determina a razão ótima de nós em cada SF, de modo a aumentar a eficiência energética. Esse problema é paramétrico, permitindo que operadores ajustem parâmetros para obter resultados mais rápidos em relação aos métodos clássicos. Com base nessas razões, utiliza-se um método de limiares de SNR adaptativos para derivar o SF de cada nó na rede. Por fim, o servidor de rede informa a cada nó seus parâmetros em uma de suas janelas de recepção, sem exigir qualquer alteração na especificação do LoRaWAN. O servidor de rede calcula os SFs ótimos após coletar todos os valores de SNR da primeira transmissão e, em seguida, as configurações de parâmetros são enviadas a cada nó após a segunda tentativa.

Em comparação com o estado da arte, o AG e o FPA configura simultaneamente SFs para todos os nós em redes LoRaWAN com múltiplos gateways. Além disso, equilibra as distribuições de pesos, não importando o tipo de modelo. Diferentemente do trabalho em [Loubany et al., 2023], cujo o CVX, por ter comportamento convexo, ou seja, busca soluções para problemas convexas, acaba tendenciando a otimização para a parte convexa ou concava da modelagem. Além disso, o tempo de execução é

comparado com o solver e com as outras metaheurísticas. Os resultados mostram que a aplicação do AG e o FPA na solução não só melhora a eficiência energética da rede como também entrega os resultados mais rápidos que o método clássico.

A organização do artigo é a seguinte: a Seção 4 apresenta os fundamentos do LoRaWAN e os métodos de otimização adotados; a Seção 5 descreve o modelo do sistema; a Seção 6 introduz o ambiente de simulação proposto; a Seção 7 detalha o algoritmo; a Seção 8 discute os resultados obtidos com a integração do algoritmo e do ambiente; por fim, as Seções 9 e 10 trazem a conclusão e as direções futuras.

4 Visão Geral

A. LoRaWAN

Nesta subseção apresentamos uma visão objetiva da tecnologia LoRa/LoRaWAN e quantificamos o time on air (ToA) — fator determinante para vazão e consumo de energia. LoRa é a camada física desenvolvida pela Semtech [Semtech Corporation, 2013], que emprega modulação Chirp Spread Spectrum (CSS) nas bandas ISM não licenciadas. Os principais parâmetros configuráveis são o SF, a potência de transmissão (TP), a BW e a CR; a escolha conjunta desses parâmetros estabelece o compromisso entre taxa de dados, cobertura e energia. Em termos práticos, aumentar o SF ou reduzir a BW eleva a sensibilidade do receptor e amplia a cobertura, porém alonga o ToA e reduz a vazão. Já aumentar BW encurta o ToA à custa de sensibilidade. Esses efeitos são consolidados nos guias de projeto dos modems Semtech.

Tabela 1: Parâmetros físicos LoRa e efeitos esperados na camada física.

Parâmetro	Ação	Efeito resumido
SF ($7 \rightarrow 12$)	\uparrow	\uparrow sensibilidade; \uparrow ToA; \downarrow Vazão
BW ($125 \rightarrow 500$ kHz)	\uparrow	\downarrow ToA; \downarrow sensibilidade
CR ($4/5 \rightarrow 4/8$)	\uparrow	\uparrow robustez; \uparrow ToA
TP (dBm)	\uparrow	\uparrow consumo do transmissor

Definindo a duração de símbolo, o tempo do preâmbulo e o número de símbolos da carga útil (N_p) são dados por:

$$T_s = 2^{\text{SF}}/\text{BW} \quad (1)$$

$$T_{\text{preamble}} = (N_{\text{preamble}} + 4.25) T_s, \quad (2)$$

$$N_p = 8 + \max \left\{ \left\lceil \frac{8 \text{ PL} - 4 \text{ SF} + 28 + 16 - 20 \text{ H}}{4 (\text{SF} - 2 \text{ DE})} \right\rceil (\text{CR} + 4) \right\} \quad (3)$$

$$T_{\text{payload}} = N_{\text{payload}} T_s, \quad (4)$$

$$T_{\text{ToA}} = T_{\text{preamble}} + T_{\text{payload}}. \quad (5)$$

Acima, PL é o tamanho da carga útil (bytes); $\text{H} \in \{0, 1\}$ indica cabeçalho explícito (0) ou implícito (1); $\text{DE} \in \{0, 1\}$ é a otimização de baixa taxa (recomendada para SF 11–12 com BW=125 kHz); e $\text{CR} \in \{1, \dots, 4\}$ corresponde à FEC $4/(4 + \text{CR})$. Para dimensionamento, usa-se tipicamente $N_{\text{preamble}} = 8$.

Tabela 2: Exemplo ilustrativo de T_s e componentes do ToA para BW=125 kHz.

SF	T_s (símbolo)	$T_{\text{preamble}} = (8 + 4,25) T_s$
7	$2^7/125,000$	$12,25 T_s$
9	$2^9/125,000$	$12,25 T_s$
12	$2^{12}/125,000$	$12,25 T_s$

A Tabela 2 evidencia que T_s cresce exponencialmente com SF (para BW fixa), tornando T_{packet} e o consumo energético por pacote sensíveis à configuração. Assim, estratégias que minimizam T_{packet} sob margens de SNR e BER viáveis tendem a aumentar a vazão e reduzir consumo, respeitando simultaneamente as limitações regulatórias de potência e duty-cycle [Semtech Corporation, 2019].

B. Solver CVX

O CVX é um framework de modelagem para programação convexa no MATLAB que permite descrever variáveis, objetivo e restrições em blocos `cvx_begin...cvx_end`. A ferramenta verifica automaticamente a conformidade com as regras de disciplined convex programming (DCP), rejeita formulações inválidas e traduz problemas válidos para formas padrão apropriadas, delegando a resolução a solucionadores compatíveis e retornando a solução diretamente no ambiente MATLAB [Grant and Boyd, 2014].

O fluxo operacional pode ser entendido como um encadeamento de etapas: a modelagem do problema é seguida da verificação DCP; uma vez aprovado, ocorre a canonização para graph form; em seguida, o problema é enviado ao solver (por exemplo, métodos de pontos interiores, conforme a variante disponível); por fim, os resultados passam por pós-processamento antes da saída. Esse pipeline está sintetizado no fluxograma da Figura 2, que também explicita o desvio para erro quando a verificação de convexidade falha.

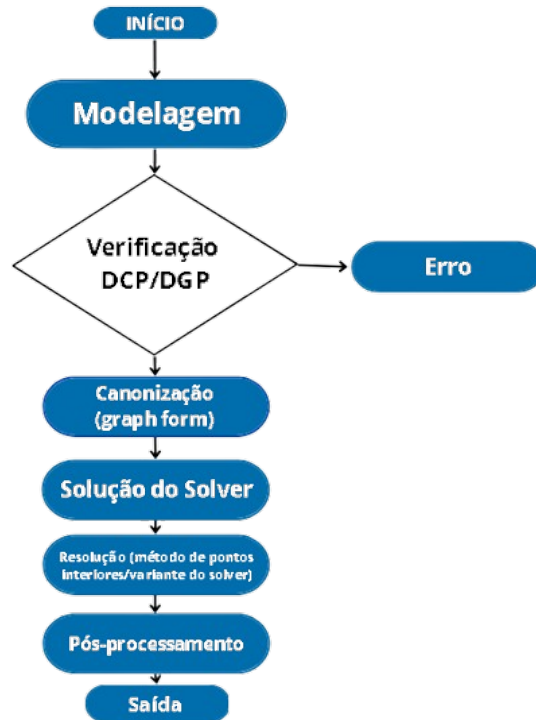


Figura 2: Fluxograma do Conjunto de Solver CVX

Na prática, o CVX reduz a distância entre a formulação matemática e a implementação, padroniza a verificação de convexidade e abstrai detalhes de chamada ao solver. O resultado é um processo de prototipagem mais confiável e reproduzível, no qual o pesquisador se concentra na modelagem e na análise, enquanto a ferramenta garante consistência do problema e execução transparente do backend de otimização.

C. Algoritmo Genético

Algoritmos Genéticos são métodos estocásticos de busca e otimização inspirados na seleção natural: mantêm uma população de soluções candidatas, avaliam sua aptidão e iteram por seleção, recombinação e mutação até um critério de parada. O arcabouço conceitual remonta a Holland, que formalizou a dinâmica de esquemas e a proliferação de padrões promissores sob operadores apropriados [Holland, 1975], e às sínteses clássicas que consolidam o “GA canônico” e suas variantes operacionais.

Na implementação, parte-se de uma codificação (binária, inteira ou real) para representar decisões; a seleção (proporcional à aptidão, roleta ou torneio) prioriza candidatos; o cruzamento (um/dois pontos ou uniforme; no contínuo, recombinação aritmética/SBX) combina informação de pais; e a mutação (bit-flip ou perturbação controlada) introduz variabilidade para explorar novas regiões. Elitismo é comumente adotado para preservar as melhores soluções entre gerações, enquanto a parametrização (tamanho populacional, taxas de cruzamento/mutação) regula o equilíbrio entre exploração e intensificação da busca [Goldberg, 1989, Mitchell, 1998].

Na Figura 3, o processo inicia com a inicialização da população e a atribuição de aptidão; em cada geração aplicam-se seleção, cruzamento e mutação sobre a população corrente. Após gerar descendentes, verifica-se o critério de terminação (por exemplo, número máximo de gerações ou estagnação da melhor aptidão). Se não satisfeito, realiza-se a seleção de sobreviventes (com elitismo/renovação) e inicia-se a próxima geração; caso contrário, retorna-se a melhor solução encontrada.

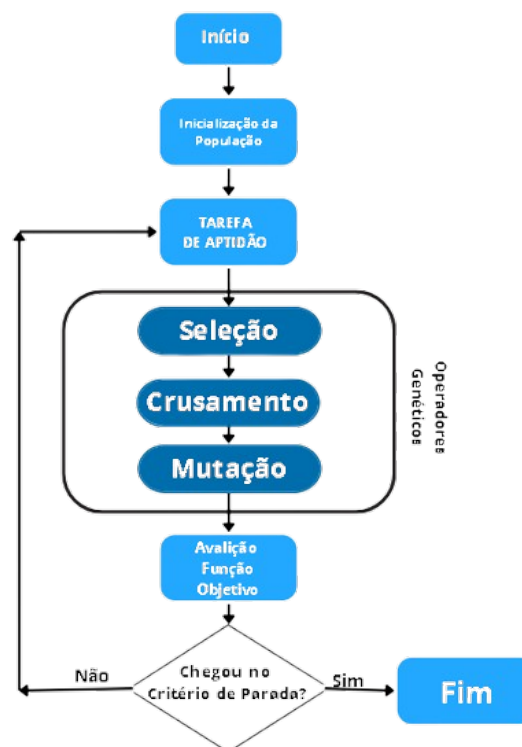


Figura 3: Fluxograma do Algoritmo Genético.

D. Algoritmo Polinização de Flores

As metaheurísticas têm se mostrado alternativas robustas para problemas complexos. O Flower Pollination Algorithm (FPA) é uma dessas abordagens, alternando entre polinização global, baseada em passos da distribuição de Lévy, e autopolinização, responsável pela exploração local. De acordo com [Faisal et al., 2020],

o funcionamento do FPA segue quatro regras: polinização global, polinização local, escolha probabilística entre os modos de polinização (probabilidade p) e atualização contínua da melhor solução global. O fluxograma é apresentado na Figura 4.

Matematicamente, a atualização na polinização global é dada por:

$$x_i^{t+1} = x_i^t + L \cdot (x_i^t - g^*)$$

em que x_i^t é a solução atual na iteração t , g^* a melhor solução global encontrada e L um passo aleatório segundo distribuição de Lévy.

Na polinização local, a atualização é:

$$x_i^{t+1} = x_i^t + \epsilon \cdot (x_j^t - x_k^t)$$

onde x_j^t e x_k^t são soluções aleatórias e $\epsilon \in [0, 1]$ é aleatório uniforme.

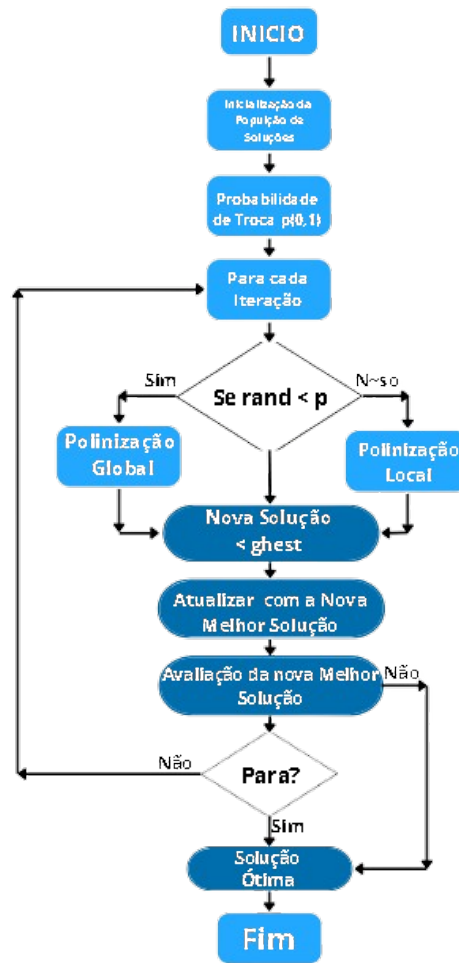


Figura 4: Fluxograma do Algoritmo Polinização de Flores

5 Modelo de Sistema

A seguir serão descritos os modelos de sistema e a modelagem do problema de Otimização.

A. Eficiência Energética em LoRaWAN

Definimos a eficiência energética como a razão entre a vazão útil efetivamente entregue e a potência média consumida, em bit/J:

$$E = \frac{\text{vazão}}{\text{potência}} = \frac{T}{P} \quad [\text{bit/J}]. \quad (6)$$

No contexto de LoRaWAN, T depende do tamanho útil do payload, da periodicidade de envio e da taxa de entrega de pacotes, afetada por colisões e retransmissões, enquanto P agrega os custos de transmissão, janelas de recepção e estados de espera/idle. Assim, reduzir o tempo no ar (ToA) por meio de escolhas adequadas de SF/BW/CR e limitar retransmissões tende a maximizar E , pois simultaneamente aumenta a vazão útil e diminui a energia gasta por ciclo. Uma análise abrangente dos impactos de protocolos e mecanismos de acesso sobre consumo e eficiência energética em LoRaWAN, portanto, sobre E é apresentada no survey de comunicações voltado a eficiência energética [Banti et al., 2022].

B. Modelo de Vazão

Adota-se um modelo de acesso aleatório do tipo ALOHA, no qual a vazão por spreading factor (SF) resulta do produto entre a taxa efetiva de chegadas e a probabilidade de sucesso de transmissão [Loubany et al., 2023]. Para um SF s , tem-se

$$T(s) = \lambda p(s) N_c n_b e^{-2G(s)}, \quad (7)$$

em que λ é a taxa de chegada de pacotes, $p(s)$ a proporção de dispositivos operando em s , N_c o número de canais disponíveis, n_b o número de bits por pacote, e $e^{-2G(s)}$ representa a probabilidade de não colisão sob a janela de vulnerabilidade igual a $2ToA$. A carga ofertada associada a s é dada por

$$G(s) = \lambda p(s) N_c ToA(s), \quad (8)$$

com $ToA(s)$ correspondendo ao tempo no ar do pacote no SF s . Para largura de banda fixa, $ToA(s)$ cresce com s , aumentando $G(s)$ e, conseqüentemente, reduzindo o termo $e^{-2G(s)}$, o que impacta negativamente $T(s)$; essa relação entre parâmetros físicos, tempo no ar e métricas de desempenho é consistente com modelagens de LoRaWAN reportadas na literatura [Casals et al., 2017].

Assumindo ortogonalidade entre SFs, a vazão total da rede é a soma das vazões individuais no intervalo $[S_{\min}, S_{\max}]$:

$$S = \sum_{s=S_{\min}}^{S_{\max}} T(s). \quad (9)$$

As expressões (7)–(9) permitem avaliar diretamente o efeito da distribuição $p(s)$ e do número de canais N_c sobre a taxa efetiva entregue, destacando $ToA(s)$ como variável crítica do custo temporal do enlace.

C. Modelo de Energia

O modelo de consumo de energia avalia o impacto das operações de transmissão, recepção, espera (standby) e inatividade (idle) em transceptores LoRa, acumulando a energia gasta por estado ao longo de um horizonte T . Em cada SF s , considera-se a fração de dispositivos $p(s)$, o número de canais N_c , a tensão de operação V e as correntes típicas de cada modo ($I_{tx}(l)$, I_{rx} , I_{st} , I_{id}), de modo a compor uma métrica agregada por SF e, depois, a soma na rede. A dependência do tempo no ar $ToA(s)$ explicita o acoplamento entre parâmetros físicos e custo energético, como usualmente documentado para modems LoRa [Semtech Corporation, 2019].

A energia consumida no período ativo para o SF s é dada por

$$E_{\text{active}}(s) = \frac{1}{2} p(s) N_c V \cdot \left[\begin{array}{l} T \cdot ToA(s) \cdot I_{tx}(l) \\ + RD_1 \cdot I_{rx} \\ + T_{rx1}(s) \cdot I_{rx} \\ + (RD_2 - T_{rx1}(s)) \cdot I_{st} \\ + (T_{rx1}(s) + T_{rx2}(s)) \cdot I_{rx} \end{array} \right], \quad (10)$$

onde os termos de recepção e espera contabilizam as janelas RX e os atrasos de downlink. O fator $\frac{1}{2}$ pondera a média temporal dentro do horizonte de avaliação, mantendo consistência com a agregação sobre T .

A energia consumida no período ocioso (idle) para o mesmo SF é

$$E_{\text{idle}}(s) = \frac{1}{2} p(s) N_c V \cdot \left[\begin{array}{l} T - ToA(s) \\ + T_{rx1}(s) \\ + RD_1 + RD_2 \end{array} \right] \cdot I_{id}, \quad (11)$$

complementando o balanço energético quando o rádio permanece em inatividade, inclusive nos intervalos que cercam as janelas de recepção.

O consumo total por SF resulta da soma das componentes ativa e ociosa,

$$E(s) = E_{\text{active}}(s) + E_{\text{idle}}(s), \quad (12)$$

e a energia total da rede é a agregação sobre o conjunto de SFs considerados,

$$\mathcal{E} = \sum_{s=S_{\min}}^{S_{\max}} E(s). \quad (13)$$

As Eqs. (10)–(13) fornecem a base para comparar configurações (por exemplo, distribuições $p(s)$ e níveis de potência l) sob o mesmo horizonte T , permitindo relacionar diretamente $ToA(s)$, tempos de recepção/espera e correntes de operação ao custo energético total.

D. Modelagem do Problema de Otimização

O desempenho de redes LoRaWAN é fortemente condicionado à alocação eficiente de dispositivos entre os diferentes spreading factors (SFs) e ao consumo energético dos transceptores, sobretudo em cenários com grande número de nós e alta densidade de tráfego. Para capturar esse compromisso, adota-se uma função de utilidade proporcionalmente justa baseada no logaritmo da vazão por SF:

$$R = \sum_{s=S_{\min}}^{S_{\max}} \log(T(s)), \quad (14)$$

onde $T(s)$ denota a taxa efetiva associada ao SF s . Substituindo a expressão de $T(s)$ no somatório, obtém-se

$$R = \sum_{s=S_{\min}}^{S_{\max}} \log(\lambda \cdot p(s) \cdot N_c \cdot b) - 2 \sum_{s=S_{\min}}^{S_{\max}} G(s), \quad (15)$$

em que λ é a taxa de chegadas agregada, $p(s)$ a proporção de dispositivos no SF s , N_c o número de canais e $G(s)$ a carga ofertada associada a s .

Com o objetivo de simultaneamente maximizar a utilidade da rede e minimizar o consumo de energia, formula-se a seleção ótima de SF como um problema baseado em multiobjetivo. A distribuição ideal $p(s)$ é obtida pela combinação linear normalizada entre a utilidade \mathcal{R} e a energia consumida \mathcal{E} em um horizonte T :

$$\max. \frac{a}{\alpha} R(p) - \frac{b}{\beta} E(p) \quad (16)$$

$$a, b \in [0, 1], \quad a + b = 1, \quad (17)$$

em que a e b ponderam a importância relativa de desempenho e energia. As constantes de normalização garantem comparabilidade entre objetivos em escalas distintas e são definidas pelos valores de Nadir e Utopia:

$$\alpha = \mathcal{R}_{\max} - \mathcal{R}_{\min}, \quad \beta = \mathcal{E}_{\max} - \mathcal{E}_{\min}. \quad (18)$$

A escolha do logaritmo em (14) induz justiça proporcional entre SFs, pois penaliza concentrações excessivas de carga em um único fator de espalhamento, reduzindo $\sum_s G(s)$ e mitigando colisões. Ao ajustar $p(s)$ para balancear a oferta de tráfego, aumenta-se a probabilidade de sucesso das transmissões e aproveita-se melhor a capacidade agregada da rede. Essa redistribuição também impacta diretamente o gasto energético dos terminais, uma vez que menor carga efetiva e menos retransmissões tendem a reduzir o consumo total, elevando a eficiência energética. Todos os modelos desta subseção seguem a formulação apresentada em [Loubany et al., 2020].

6 Simulação

A simulação foi realizada em Matlab com base em [Loubany et al., 2023], considerando uma rede LoRaWAN com 4500 nós sensores e quatro gateways distribuídos uniformemente em uma área de 7 km², como na Figura 5. Adotou-se o transceptor LoRa SX1272 para todos os nós, altura de 30 m para os gateways e 1,5 m para os nós em relação ao nível do mar; a figura evidencia a distribuição regular dos gateways e o espalhamento dos nós no plano, definindo o cenário de propagação e recepção utilizado.

Tabela 3: Consumo de corrente por [Semtech Corporation, 2013]

TP [dBm]	I_{tx} [mA]
2	24
5	25
8	25
11	32
14	44

Os parâmetros do modelo incluem a taxa de geração de pacotes λ , o ciclo de trabalho d , o tamanho do *payload* k , o comprimento do preâmbulo n_{pream} , as durações das janelas de recepção $T_{rx1}(s)$ e $T_{rx2}(s)$, os atrasos de recepção RD_1 e RD_2 , as correntes I_{tx} , I_{rx} , I_{st} , I_{id} , a tensão de operação V , o número de canais N_c e o tempo no ar $ToA(s)$.

A Tabela ?? mostra que, em 2 e 5 dBm, o consumo permanece entre 24 e 25 mA, enquanto em 11 e 14 dBm cresce para 32 e 44 mA, respectivamente, refletindo o aumento de corrente com a elevação da potência de transmissão.

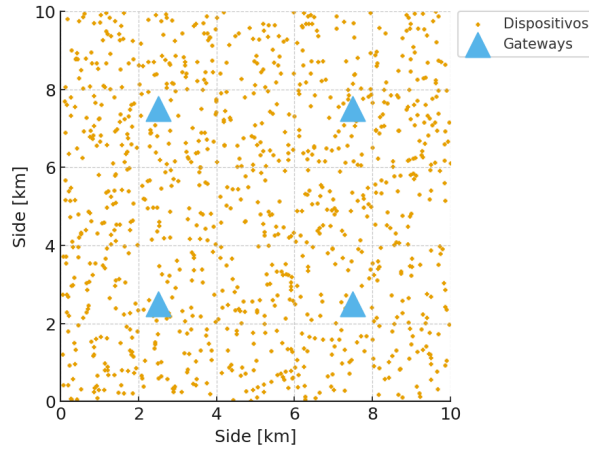


Figura 5: Estudo de Caso

Emprega-se o modelo de perda de percurso de Okumura–Hata para ambiente urbano/denso, com fatores de espalhamento de 7 a 12 e potências de transmissão de 2, 5, 8, 11 e 14 dBm. A portadora é 868 MHz, com largura de banda de 125 kHz e taxa de codificação 4/5, seguindo [Loubany et al., 2023].

Os dispositivos utilizam antenas omnidirecionais de 3 dBi; as alturas são 30 m (gateways) e 1,5 m (nós). $\lambda = 6$ pacotes/h, cada pacote com 40 bytes de *payload*; a simulação dura 720 s, $T_{rx1}(s) = [1.1048, 1.1802, 1.3211, 1.5636, 2.0485, 2.9398]$ e $T_{rx2}(s) = [2.1048, 2.1802, 2.3211, 2.5636, 3.0485, 3.9398]$; com o $RD_1 = 1$ s e $RD_2 = 2$ s. Para a avaliação energética consideram-se tensão de operação ($V = 3,3$ V), corrente de transmissão ($I_{tx} = 44$) mA, corrente de recepção ($I_{rx} = 10,5$) mA, corrente no modo inativo ($I_{st} = 1,4$) mA e corrente no modo ocioso ($I_{id} = 1,5 \mu$) A, com bateria de 1800 mAh por nó, conforme resumido na Tabela 4.

Parâmetro	Valor
Número de nós (N_c)	[500-4500]
Número de gateways (r)	4
Disposição da rede	Quadrado, lado de 7 km
Modelo de perda de percurso	Okumura-Hata urbano/denso
Fator de espalhamento (SF)	{7, 8, 9, 10, 11, 12}
Potência de transmissão (TP)	{2, 5, 8, 11, 14} dBm
Frequência portadora	868 MHz
Largura de banda	125 kHz
Taxa de codificação	4/5
Antena ED/GW	3 dBi omnidirecional
Altura do gateway	30 m
Altura dos nós	1,5 m
Taxa de geração de pacotes (λ)	6 pacotes/h
Comprimento do payload (k)	40 bytes
Duração da simulação (T)	720 s
$T_{rx1}(s)$	{1.1048, 1.1802, 1.3211, 1.5636, 2.0485, 2.9398}
$T_{rx2}(s)$	{2.1048, 2.1802, 2.3211, 2.5636, 3.0485, 3.9398}
RD ₁	1 s
RD ₂	2 s
V	3,3 V
I_{tx}	44 mA
I_{rx}	10,5 mA
I_{st}	1,4 mA
I_{id}	1,5 μ A
Capacidade da bateria dos nós (C)	1800 mAh

Tabela 4: Parâmetros utilizados na simulação da rede LoRaWAN.

Esses parâmetros permitem analisar a relação entre configuração física e desempenho temporal do enlace; a Tabela 5 apresenta, por SF, o tempo no ar e a taxa resultante de pacotes por hora, possibilitando avaliar vazão, consumo de energia, eficiência de comunicação e autonomia dos dispositivos no intervalo de densidades considerado.

SF	ToA [s]	λ [pacotes/h]
7	0.1048	343.32
8	0.1802	199.75
9	0.3211	112.10
10	0.5636	63.87
11	1.0485	34.33
12	1.9398	18.55

Tabela 5: Resultados da simulação

Para caracterização adicional do cenário, os dispositivos foram configurados para transmitir pacotes em intervalos regulares com monitoramento contínuo do consumo energético; as mensagens incluem identificação do dispositivo, leituras de temperatura, indicador de força do sinal e relação sinal-ruído, mantendo a operação no contexto de telemetria definido.

7 Aplicação dos Métodos de Otimização

Com base nas métricas obtidas e na metodologia de [Loubany et al., 2023], aplicaram-se o método CVX para avaliar vazão e consumo de energia variando a distribuição dos fatores de espalhamento (SF) entre os dispositivos. Adotou-se alocação linear e ortogonal: nós com maior SNR foram associados a SF menores, enquanto nós com menor SNR utilizaram SF maiores. Essa regra reduz o tempo de transmissão dos enlaces mais favoráveis e amplia o alcance nos enlaces degradados. A otimização é guiada pelo algoritmo 1, que trata o problema como multiobjetivo: maximiza a utilidade da rede e a eficiência de transmissão e minimiza o modelo de consumo energético. A variável de decisão é a proporção $p(s)$ de dispositivos alocados a cada SF, cuja seleção ideal visa maximizar o desempenho global.

```

foreach combinação de pesos do
  foreach valor de  $N_c$  do
    Otimização para maximizar a utilidade da rede:  $R_{\max}$ 
    Otimização para minimizar o consumo de energia:  $E_{\max}$ 
    Calcular  $\alpha = R_{\max} - R_{\min}$  e  $\beta = E_{\max} - E_{\min}$ 
    Otimização para maximizar a eficiência: EFF
    Armazenar vazão e energia
  end
  Atualizar  $X_{all}$  (Vazão de Dados Total) e  $Y_{all}$  (Consumo Energético Total)
end

```

Algorithm 1: Pseudocódigo simplificado da otimização aplicada

A formulação combina linearmente as funções objetivo, ponderadas por A e B (com $A + B = 1$), controlando a influência relativa da vazão e do consumo. Para evitar distorções por escala, normalizam-se as funções com α e β , obtidas pelas diferenças entre valores máximos e mínimos observados em análises prévias.

As restrições são

$$\sum_{i=1}^{n_{sf}} p_i = 1, \quad (19)$$

$$p_i \geq 0, \quad \forall i, \quad (20)$$

$$p_i \leq 1, \quad \forall i, \quad (21)$$

garantindo distribuição factível das proporções de SF. Como a alocação é ortogonal, a implementação das restrições é direta e favorece a convergência.

Em termos operacionais, o algoritmo 1 percorre combinações de pesos A e B e valores de N_c para mapear o espaço de compromisso entre desempenho e energia. Em cada iteração, resolve-se sequencialmente a maximização de R e a minimização de E para obter (R_{\max}, R_{\min}) e (E_{\max}, E_{\min}) , calcula-se (α, β) e, então, otimiza-se a métrica composta no problema formulado na equação 16. Os resultados de vazão e energia são acumulados para posterior análise comparativa.

A atualização de X_{all} e Y_{all} ao final de cada ciclo registra, respectivamente, o tamanho da rede e as métricas agregadas (vazão total ou consumo energético total), permitindo traçar curvas de desempenho por densidade de nós. Esse procedimento evidencia como a distribuição $p(s)$ responde às variações de peso e capacidade, preservando a consistência com as restrições e com a regra de alocação linear/ortogonal por SNR.

Optar por metaheurísticas como AG em lugar de resolver exclusivamente via CVX é vantajoso quando se deseja explorar diretamente distribuições $p(s)$ sob múltiplos pesos, topologias e capacidades sem reconfigurar a formulação a cada cenário. AG lida bem com variáveis proporcionais e limites simples, produzindo soluções competitivas em tempo prático e mantendo diversidade de candidatos para escapar de alocações subótimas induzidas por assimetrias de SNR.

Também, o FPA é adequado para refinar $p(s)$ quando a superfície de eficiência apresenta vales rasos e múltiplos picos locais. Por operar com passos globais e locais balanceados, o FPA tende a ajustar finamente as proporções entre SFs respeitando as restrições, o que é útil para estabilizar o compromisso entre vazão e energia em redes densas e com múltiplos canais, dentro do mesmo arcabouço multiobjetivo descrito acima.

Dessa forma, construímos um sistema de avaliação em três etapas encadeadas: (i) otimização para maximizar a utilidade da rede; (ii) otimização para minimizar o consumo de energia; (iii) cálculo das normalizações da equação 18, seguido da otimização para maximizar a eficiência composta. Esse ciclo é iterado enquanto houver combinações de pesos e configurações a avaliar; caso contrário, o processo é encerrado. A Figura 6 resume esse fluxo do algoritmo 1, evidenciando o laço de repetição entre as etapas de otimização e o bloco de cálculo de α e β até a condição de parada ser satisfeita.

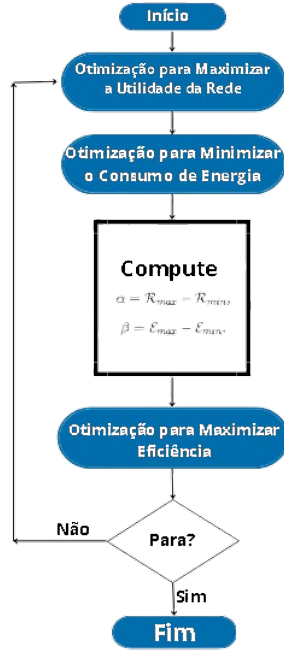


Figura 6: Fluxograma do Algoritmo 1

8 Resultados

A avaliação considerou duas métricas fundamentais para redes de comunicação de baixa potência e longo alcance: a vazão de dados e o consumo de energia dos dispositivos finais. A Figura 7 apresenta a relação entre a vazão da rede e o número de nós, considerando diferentes distribuições de pesos atribuídos à função de utilidade da rede e ao consumo de energia. O CVX apresenta os maiores valores de vazão em quase todos os cenários analisados. Este comportamento destaca a capacidade do CVX de explorar o espaço de busca de soluções de forma eficiente em modelos convexos, maximizando a taxa de transferência de dados, especialmente quando o peso atribuído à função de utilidade é elevado.




Figura 7: Histogramas de Vazão para diferentes distribuições de pesos

No entanto, o método AG exibe desempenho intermediário em termos de vazão, ficando próximo ao CVX em cenários onde o peso da utilidade é dominante, mas apresentando ligeira redução em contextos onde a distribuição de peso do consumo energético é acrescentada. O método FPA, por sua vez, apresenta as menores taxas de vazão em quase todos os cenários, refletindo sua característica de buscar soluções mais balanceadas e menos agressivas em termos de desempenho extremo. A tendência geral observada na Figura 7 mostra que todos os métodos respondem de maneira crescente ao aumento do número de nós, com crescimento quase linear da vazão até 4000 dispositivos. Essa resposta confirma a escalabilidade dos métodos aplicados, ainda que com diferentes níveis de desempenho.

Na questão de consumo de energia, a Figura 8 apresenta a relação entre o gasto energético acumulado e o número de nós para os diferentes métodos e combinações de pesos. O FPA se destaca por apresentar consistentemente os menores valores de consumo energético, independentemente do cenário de peso atribuído. Esse comportamento evidencia a eficiência do algoritmo na busca por eficiência energética favorável, por possui equilíbrio na exploração global e exploração local que tornam a sua busca mais diversa. E o CVX, que embora apresente alta vazão, tem a maior energia consumida entre os três métodos avaliados. Esse resultado reflete o trade-off clássico entre vazão e consumo energético em sistemas de comunicação: a maximização da taxa de transmissão geralmente implica em maiores custos energéticos.

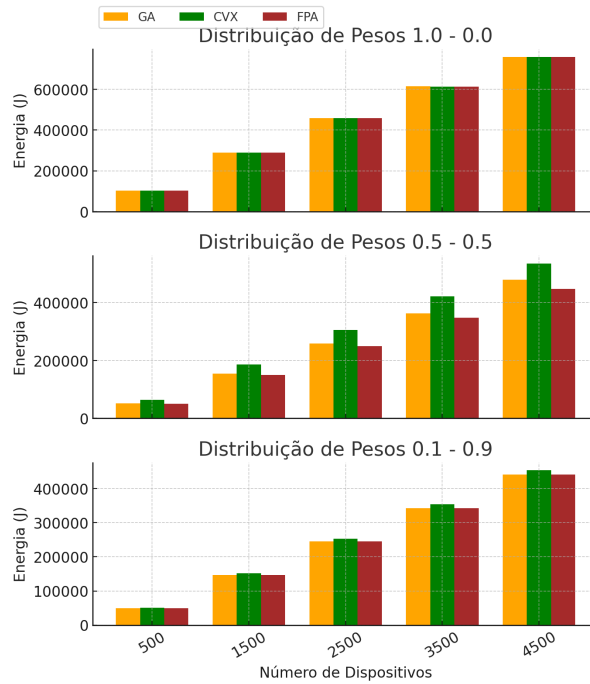


Figura 8: Histogramas de Energia para diferentes distribuições de pesos

O AG novamente ocupa uma posição intermediária, apresentando consumo energético moderado e comportamento mais estável conforme os pesos variam. Sua resposta ao ajuste dos pesos é o mais linear e previsível, o que pode ser vantajoso em cenários onde a previsibilidade e a robustez do sistema são mais valorizadas do que a otimização extrema de uma única métrica. Ao analisar os efeitos da variação dos pesos, observa-se que, conforme aumenta-se a importância atribuída ao consumo energético (pesos como (0.10, 0.90)), todos os métodos tendem a reduzir a vazão e a energia consumida, como esperado. No entanto, o FPA apresenta maior sensibilidade à variação dos pesos, ajustando-se de forma mais eficaz aos requisitos energéticos. O CVX, por sua vez, mantém vazões elevadas mesmo em cenários que priorizam a minimização da energia, mas ao custo de maior consumo energético.

Figura 9 compara GA, CVX e FPA em três cenários de pesos (1.0–0.0, 0.5–0.5 e 0.1–0.9) ao longo do aumento do número de dispositivos. No caso 1.0–0.0, os métodos apresentam valores muito próximos em todas as densidades (diferenças marginais). Nas distribuições 0.5–0.5 e 0.1–0.9, o AG se destaca nas menores escalas (até 1500 nós), mantendo eficiência superior às alternativas; à medida que a rede se torna mais densa (2500 nós), as curvas convergem e as barras indicam desempenho semelhante entre os três métodos, com equidade nas maiores cargas (3500–4500 nós). Em todos os cenários observa-se a tendência esperada de queda de eficiência com o aumento de dispositivos, refletindo maior ocupação do canal e impacto de colisões.

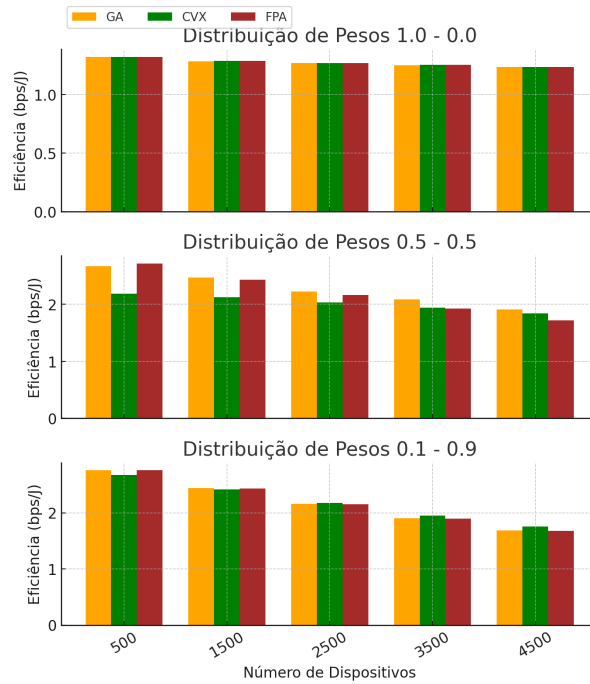


Figura 9: Histogramas de Eficiência para diferentes distribuições de pesos

Todos os cenários foram executados em um desktop Intel(R) Core(TM) i5-1035G1 CPU @ 1.00GHz (1.20 GHz) com 16,0 GB de RAM. A análise do tempo de execução, mostrada na tabela 6 para cada abordagem, considerando todas as distribuições de pesos aplicadas à rede LoRaWAN, revelou diferenças significativas no desempenho computacional. O tempo necessário para resolver o problema baseado em multiobjetivo que envolve a maximização da vazão e a minimização do consumo energético foi medido em segundos.

Tabela 6: Tempo de execução por método.

Método	Tempo total (s)	Tempo por cenário (Número de Nós)
CVX	173.5661	4.3391
FPA	5.43	0.13
AG	7.53	0.18

Nas Figuras 10 e 11, observa-se o padrão de convergência do fitness ao longo de 200 iterações para cinco distribuições de pesos. Na Figura 10 (FPA), as curvas apresentam crescimento rápido nas primeiras iterações (aprox. 0–10), seguido por ganhos marginais até a estabilização entre 20 e 200 iterações, sem oscilações visíveis após o platô. A separação entre as curvas é nítida e permanece estável ao longo do horizonte: a configuração (0.10, 0.90) mantém os maiores valores de fitness. As combinações (0.50, 0.50) e (1.00, 0.00) situam-se em níveis intermediários próximos. O comportamento é monotônico e consistente, com o ordenamento preservado desde o início até o regime estacionário.




Figura 10: Gráfico de Convergência FPA

A Figura 11 exibe o mesmo desenho geral de evolução do fitness para o AG: aceleração inicial, aproximação gradual ao platô e estabilização no mesmo intervalo de iterações observado no FPA. O

ordenamento final entre as distribuições de pesos também se repete, com (0.10, 0.90) no topo, (0.50, 0.50) e (1.00, 0.00) em patamares intermediários. Assim, as duas figuras indicam trajetórias de convergência visualmente semelhantes, tanto na velocidade de subida nas iterações iniciais quanto na manutenção das diferenças relativas entre as distribuições de pesos após a estabilização




Figura 11: Gráfico de Convergência AG

Observa-se que o método CVX apresentou um tempo de processamento significativamente superior, sendo cerca de 24 vezes mais lento que o AG e 27 vezes mais lento que o FPA, o que é esperado, pois a programação convexa exige a construção e solução de sistemas de equações complexos, enquanto métodos bioinspirados como FPA e AG, que não apresentaram grandes diferenças na convergência, utilizam buscas heurísticas baseadas em populações, tornando o processo mais ágil. Esses resultados destacam a vantagem dos métodos metaheurísticos para otimização de redes LoRaWAN de grande escala, com o AG se destacando pela eficiência, ideal para aplicações com restrições de vazão máxima e consumo mínimo de energia, e o FPA, embora menos eficiente, sendo uma alternativa rápida em comparação ao AG e CVX.

9 Conclusão

Os resultados mostraram que o método CVX, embora robusto e tradicional, apresenta um tempo de processamento elevado, tornando-se menos viável para aplicações em redes de grande escala que exigem respostas rápidas. Em contrapartida os métodos FPA e AG demonstraram tempos de execução muito inferiores, com destaque para o AG, que apresentou a maior eficiência. O FPA, apesar de sua performance ser inferior que a do AG, alcançou resultados mais rápidos entre todos os métodos analisados, sendo a melhor escolha para cenários onde a prioridade é o tempo de execução. No AG destacou-se em aplicações que exigem eficiência energética rigorosa. Assim, a escolha do método de otimização deve considerar o perfil da aplicação, o compromisso entre vazão e consumo de energia, e as restrições de tempo de processamento.

10 Trabalhos Futuros

Como futuros trabalhos, pretende-se complementar o cenário incorporando dinamicidade no posicionamento dos nós sensores com mobilidade afim avaliar o comportamento das metaheurísticas, além da integração de uma abordagem baseada em Deep Reinforcement Learning (DRL). A análise futura será conduzida comparando o desempenho das metaheurísticas clássicas com técnicas de aprendizado por reforço profundo, avaliando ganhos em eficiência, escalabilidade e adaptação em ambientes dinâmicos.

Referências

- [Abdelhedi et al., 2025] Abdelhedi, M. A., Trabelsi, H., and Derbel, F. (2025). Performance evaluation of lorawan physical transmission parameters. In *2025 IEEE 22nd International Multi-Conference on Systems, Signals & Devices (SSD)*, pages 1180–1185. IEEE.
- [Al-zamili and Al-Zubaidi, 2024] Al-zamili, J. J. and Al-Zubaidi, H. A. (2024). Optimizing iot wireless sensor networks: A comparative analysis of particle swarm optimization (pso) and genetic algorithms (ga). *Fusion: Practice and Applications*, 15(02):278–287.
- [Banti et al., 2022] Banti, K., Karampelia, I., Dimakis, T., Boulogeorgos, A. A., Kyriakidis, T., and Louta, M. (2022). Lorawan communication protocols: A comprehensive survey under an energy efficiency perspective. *Telecom*, 3(2):322–357.

-
- [Casals et al., 2017] Casals, L., Mir, B., Vidal, R., and Gomez, C. (2017). Modeling the energy performance of lorawan. *Sensors*, 17(10).
- [Faisal et al., 2020] Faisal, M. et al. (2020). Review of flower pollination algorithm: Applications and variants. In *IEEE*.
- [Goldberg, 1989] Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley.
- [Grant and Boyd, 2014] Grant, M. and Boyd, S. (2014). *CVX: Matlab Software for Disciplined Convex Programming*.
- [Holland, 1975] Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press.
- [Javaid et al., 2022] Javaid, M., Haleem, A., Singh, R. P., and Suman, R. (2022). Enhancing smart farming through the applications of agriculture 4.0 technologies. *International Journal of Intelligent Networks*, 3:150–164.
- [Jiang et al., 2022] Jiang, S., Zou, J., Yang, S., and Yao, X. (2022). Evolutionary dynamic multi-objective optimisation: A survey. *ACM Computing Surveys*, 55(4):76:1–76:47.
- [Loubany et al., 2020] Loubany, A., Lahoud, S., and El Chall, R. (2020). Adaptive algorithm for spreading factor selection in lorawan networks with multiple gateways. *Computer Networks*.
- [Loubany et al., 2023] Loubany, A., Lahoud, S., Samhat, A. E., and El Helou, M. (2023). Joint throughput-energy optimization in multi-gateway lorawan networks. *Telecommunication Systems*, 84(2):271–283.
- [Maurya et al., 2024] Maurya, P., Sørensen, T. B., and Sharma, H. (2024). The impact of lorawan relay mode on iot end node energy consumption. In *2024 IEEE International Workshop on Metrology for Agriculture and Forestry (MetroAgriFor)*, pages 683–688. IEEE.
- [Mekki et al., 2019] Mekki, K., Bajic, E., Chaxel, F., and Meyer, F. (2019). A comparative study of lpwan technologies for large-scale iot deployment. *ICT Express*, 5:1–7.
- [Mitchell, 1998] Mitchell, M. (1998). *An Introduction to Genetic Algorithms*. MIT Press.
- [Neves et al., 2024] Neves, I. I. A., Fernandes, F. C., Cardoso, C. M. M., Barros, F., and Araújo, J. P. L. (2024). Determinação Ótima de spread factor (sf) em redes iot-lora. In *ENCOM 2024*, Brasil.
- [Sahu and Tripathi, 2024] Sahu, R. and Tripathi, P. (2024). Enhancing energy efficiency in smart agriculture: Ga based optimization for large-scale lorawan networks. In *ICACRS*, pages 553–561. IEEE.
- [Semtech Corporation, 2013] Semtech Corporation (2013). *SX1272/3/6/7/8 LoRa Modem Design Guide*. Application Note AN1200.13, Revision 1, July 2013.
- [Semtech Corporation, 2019] Semtech Corporation (2019). *SX1272/3 datasheet, rev. 4.*. Semtech Corporation. Rev. 0.0, 11th Jan 2019.
- [Wang et al., 2024] Wang, H., Zhang, X., Liao, J., Zhang, Y., and Li, H. (2024). An improved adaptive data rate algorithm of lorawan for agricultural mobile sensor nodes. *Computers and Electronics in Agriculture*, 219:108773.
- [Zheng et al., 2024] Zheng, J., Ning, J., Ma, H., and Liu, Z. (2024). A dynamic parameter tuning strategy for decomposition-based multi-objective evolutionary algorithms. *Applied Sciences*, 14(8):3481.